

¿Qué, Dónde y a Qué?

*Sistema de extracción automática de incidencias
mediante Procesamiento de Lenguaje Natural*

Juan Cruz Rey, Juan Ignacio Pintarelli, Mateo Chiza, Paula Goldenhorn

1. El problema de negocio

Las incidencias operativas interrumpen clases y generan pérdida de tiempo.



Escenario actual

1. Surge problema.
2. Docente abandona clase.
3. Busca asistencia.
4. Espera resolución.



Impactos

1. Pérdida de tiempo.
2. Interrupción de clases.
3. Gestión manual.
4. Información incompleta.

2. Solución Propuesta

El sistema transforma mensajes escritos naturalmente en tickets estructurados



Entrada

*"No tengo marcadores
en el aula 4"*



Procesamiento

Extracción mediante
Modelo de NER para
identificar entidades
clave.



Salida

PROBLEMA: no tengo
OBJETO: marcadores
LUGAR: aula 4

3. ¿Qué es NLP y NER?

El sistema identifica automáticamente información importante dentro del texto

- **NLP:** Permite que las computadoras comprendan lenguaje humano.
- **NER:** Detecta entidades relevantes dentro de una oración.

“No funciona el proyector en el laboratorio”

PROBLEMA

OBJETO

LUGAR

4. Desafío principal: ambigüedad

La misma palabra puede significar cosas distintas según el contexto

“Puerta de entrada”

Caso 1

OBJETO

Caso 2

LUGAR

5. Estrategia del proyecto

Se siguió un proceso experimental y comparativo

Etapas

1. Construcción del dataset.
2. Etiquetado de entidades.
3. Entrenamiento de modelos.
4. Evaluación.
5. Integración con Telegram.

6. Dataset

No existen datasets públicos para este dominio específico

- 570 ejemplos.
- Dataset sintético.
- 3 entidades: **OBJETO**, **PROBLEMA** y **LUGAR**

7. Modelos evaluados

Se compararon enfoques modernos y tradicionales

Modelo	Tipo
spaCy lg	Modelo pre entrenado grande
spaCy sm	Modelo pre entrenado pequeño
CRF	Modelo probabilístico clásico

8. ¿Cómo se evaluó?

En este proyecto era más importante minimizar falsos negativos

- **Métricas:** Precisión, Recall y F1-score
- **Falso Positivo:** el modelo asigna incorrectamente una etiqueta → minimizarlo prioriza detección correcta de entidades.

¿Inventa entidades?

- **Falso Negativo:** el modelo omite una entidad → minimizarlo favorece identificar la mayor cantidad de entidades.

¿Omite entidades?

9. Resultados principales


El modelo CRF obtuvo el mejor desempeño general

spaCy lg

CRF

spaCy sm


Comparación de modelos por métrica




10. Análisis de errores

Ciertos casos son difíciles de capturar...


spaCy lg



CRF




spaCy sm




10. Análisis de errores

Los modelos CRF y spaCy sm reducen la proporción de falsos negativos


spaCy lg



CRF



spaCy sm



Total errores:

80

74

76

11. Integración

Telegram → modelo → entidades → ticket

Escenario 1

Mensaje estructurado



Escenario 2

Mensaje no estructurado



11. Integración

Telegram → modelo → entidades → ticket

Escenario 3

Mensaje sin entidades

No se detectaron entidades. 15:49

Donde curso hoy? 15:49✓✓

Escenario 4


Mensaje con caracteres especiales

Entidades detectadas:
PROBLEMA: No hay
OBJETO: marcadores verdes
LUGAR: aula 05-06
15:50

No ha@@y marcadores verdes en el aula 05—06 🤔🤔🤔🤔 15:50✓✓

12. Conclusión

El ranking del rendimiento de los modelos es el siguiente:



12. Conclusión

La solución demuestra viabilidad para automatizar procesos operativos simples mediante PLN

Problema

Las incidencias operativas generan interrupciones y gestión manual.

Solución

Un sistema PLN capaz de transformar lenguaje natural en tickets estructurados.

13. Limitaciones y Próximos pasos

Oportunidades de mejora



Limitaciones

- Dataset sintético
- Tamaño del dataset
- Los casos reales pueden ser más complejos



Próximos pasos

- Ampliar dataset
- Incorporar Transformers tipo BERT
- Utilizar LLMs e in-context learning

Pregunta final

¿Por qué un modelo neuronal, complejo y potente tiene peor rendimiento que un modelo estadístico simple?



¡Gracias!